

Projet H419

Détection de la Covid-19 sur Radiographies thoraciques par CNN

MBIAMI NJANANG CLAUDE

AVRIL 2025

Résumé

Ce projet s'inscrit dans le contexte de la pandémie de COVID-19 et vise à développer un outil de diagnostic automatique à partir d'images de radiographie thoracique. À l'aide d'un réseau de neurones convolutif (CNN), nous avons entraîné un modèle pour distinguer trois catégories : COVID-19, infection virale autre que COVID-19, et images normales. Le modèle a été entraîné sur des données publiques de 1196 images, puis évalué sur un jeu de test indépendant. Avec une précision globale de 88,5%, les résultats obtenus sont prometteurs pour une future intégration en milieu clinique.

1. Introduction

La classification est un processus d'attribution d'étiquettes ou de catégories à des données en fonction de caractéristiques communes ou de similarités. La classification peut être supervisée ou non supervisée : La classification supervisée implique l'utilisation de données d'entraînement étiquetées pour prédire l'étiquette d'une nouvelle donnée. La classification non supervisée, en revanche, ne suppose pas de données étiquetées et cherche plutôt à trouver des motifs ou des structures cachés dans les données non étiquetées. Pour notre projet, nous avons à faire à une classification supervisée. Le diagnostic de la COVID-19 par imagerie radiographique est devenu un complément important aux tests PCR, surtout dans les contextes d'urgence ou de pénurie de tests. L'automatisation de l'analyse radiographique grâce à l'intelligence artificielle, et

notamment les CNN, permettrait de fournir une aide au diagnostic rapide et efficace dans des environnements sous-équipés.[1]

2. Méthodologie

2.1 Architecture du CNN

Le modèle utilisé est un réseau de neurones convolutif simple mais efficace, composé de :

- 3 couches de convolution + MaxPooling
- 1 couche Flatten
- 1 couche Dense (256 neurones, ReLU)
- 1 couche de sortie (3 neurones, Softmax)

Fonction de perte : `categorical_crossentropy`

Optimiseur : Adam

Dropout : 0.4 pour éviter le surapprentissage




FIGURE 1 – Architecture du réseau de neurones convolutif utilisé

2.2 Détail de l'architecture du modèle CNN

Le modèle de classification est basé sur un **réseau de neurones convolutif** conçu pour traiter des images radiographiques et identifier

trois classes : COVID-19, infection virale non-COVID, et images normales. L'architecture est la suivante :

- **3 couches convolutionnelles + Max-Pooling** : Chaque couche convolutive extrait des caractéristiques locales importantes de l'image (bords, textures, motifs pulmonaires). Chaque convolution est suivie d'un *MaxPooling* pour réduire les dimensions spatiales tout en conservant les informations essentielles.
- **1 couche *Flatten*** : Elle transforme la sortie des couches convolutionnelles en un vecteur 1D, nécessaire pour la transition vers les couches entièrement connectées.
- **1 couche Dense (256 neurones, activation ReLU)** : Cette couche permet de combiner les caractéristiques extraites et d'apprendre des représentations plus abstraites. L'activation ReLU introduit de la non-linéarité et améliore l'apprentissage.
- **Dropout (taux = 0.4)** : Appliqué après la couche Dense, ce mécanisme désactive aléatoirement 40% des neurones à chaque itération d'entraînement, afin de prévenir le surapprentissage.
- **1 couche de sortie (3 neurones, activation Softmax)** : Elle génère les probabilités associées aux trois classes cibles. La fonction Softmax permet de normaliser les scores pour interprétation comme des probabilités.

Les paramètres d'entraînement du modèle sont les suivants :

- **Fonction de perte** : `categorical_crossentropy`, adaptée à la classification multiclasse.
- **Optimiseur** : Adam (Adaptive Moment Estimation), pour une convergence rapide et stable.




FIGURE 2 – Illustration de l'opération de convolution : un filtre glisse sur l'image d'entrée pour extraire des caractéristiques locales.

2.3 Environnement et bibliothèques

Le développement du modèle a été réalisé dans un environnement Python, à l'aide de bibliothèques spécialisées en apprentissage automatique et en traitement d'images :

- **TensorFlow / Keras** : Bibliothèque principale utilisée pour construire, entraîner et évaluer le réseau de neurones convolutif (CNN). Keras, intégré à TensorFlow, fournit une interface de haut niveau permettant de définir facilement les architectures de modèles, les fonctions de perte, les optimisateurs et les métriques.
- **Scikit-learn (sklearn)** : Utilisé pour le calcul des métriques d'évaluation comme la précision, le rappel, le F1-score, ainsi que pour la génération des matrices de confusion et des rapports de classification. Elle est aussi utile pour le traitement et la manipulation des jeux de données.
- **Matplotlib** : Bibliothèque de visualisation utilisée pour tracer les courbes d'apprentissage (*accuracy*, *loss*), ainsi que les visualisations d'exemples d'images, de prédictions ou de matrices de confusion.[2]

3. Données

3.1 Origine

Les données proviennent d'un ensemble Kaggle intitulé *COVID-19 Chest X-ray*, conte-

nant des radiographies étiquetées manuellement.[3]

Ensemble	COVID-19	Virus non-COVID	Normal	Total
Train	236	346	374	956
Validation	29	43	46	118
Test	30	44	48	122

TABLE 1 – Répartition des données

Les images ont été redimensionnées en 224x224, converties en niveaux de gris, et normalisées sur l'intervalle $[0,1]$.




FIGURE 3 – Visualisation de quelques images de la Data : Normal, COVID-19, Infection virale.

4. Prétraitement et augmentation des données

Afin d'accroître la robustesse du modèle et d'améliorer sa capacité de généralisation, plusieurs techniques de prétraitement et d'augmentation ont été appliquées aux images du jeu d'entraînement, via l'objet `ImageDataGenerator` de Keras. Ces transformations visent à reproduire des variations réalistes observées en imagerie médicale tout en réduisant les risques de surapprentissage.

- **Normalisation des pixels** (`rescale=1./255`) : Les valeurs de pixels sont ramenées dans l'intervalle $[0, 1]$, ce qui facilite l'apprentissage en

assurant une échelle uniforme pour toutes les entrées.

- **Rotation aléatoire** (`rotation_range=30`) : Les images peuvent être pivotées aléatoirement jusqu'à $\pm 30^\circ$, simulant des erreurs d'orientation lors de la prise de vue.
- **Zoom aléatoire** (`zoom_range=0.2`) : Un facteur de zoom variant de $\pm 20\%$ est appliqué afin de rendre le modèle plus robuste aux différences d'échelle dans les images pulmonaires.
- **Renversement horizontal** (`horizontal_flip=True`) : Les images sont retournées horizontalement de façon aléatoire, introduisant une symétrie qui enrichit la diversité des exemples vus par le modèle.
- **Variation de luminosité** (`brightness_range=[0.8, 1.2]`) : La luminosité est ajustée dans une plage donnée pour simuler les différences d'éclairage et de qualité de capture.
- **Cisaillement** (`shear_range=0.2`) : Une déformation affine de type cisaillement est appliquée, modifiant l'angle des objets dans l'image et augmentant la tolérance du modèle aux variations géométriques.
- **Translation horizontale et verticale** (`width_shift_range=0.2`) et (`height_shift_range=0.2`) : Les images peuvent être décalées jusqu'à 20% de leur largeur ou hauteur, reproduisant des cas de centrage imparfait.

L'ensemble de ces transformations contribue à augmenter la diversité du jeu d'entraînement sans ajouter de nouvelles images, ce qui permet d'améliorer la capacité de généralisation du modèle sur des données inconnues.

5. Résultats et Interprétation

5.1 Courbes d'entraînement

Le modèle s'améliore jusqu'à l'époque 16, avec `val_loss` minimale de 0.2666. `EarlyStopping` évite le surapprentissage.

- **Précision** : 92.3% à l'époque 11, 90.6% à l'époque 20
- **Perte** : 0.62 (début), 0.26 (min), 0.29 (fin)




FIGURE 4 – Courbe d'évolution de la précision durant l'entraînement.

L'analyse de la courbe d'accuracy montre une amélioration progressive de la performance du modèle tout au long des premières époques. L'accuracy atteint une valeur maximale autour de la 16^e époque, suggérant que le modèle a bien appris à distinguer les différentes classes présentes dans les données. Par ailleurs, la stabilisation de l'accuracy en fin d'entraînement, sans signe de surapprentissage évident, témoigne de la bonne généralisation du modèle sur les données de validation.




FIGURE 5 – Courbe d'évolution de la perte durant l'entraînement.

La courbe de perte présente une diminution ré-

gulière au fil des époques, atteignant une valeur minimale vers la 16^e époque. Cette tendance indique que le modèle réduit progressivement l'erreur sur les données, ce qui reflète une bonne capacité d'apprentissage. L'absence de remontée notable de la loss sur les données de validation confirme également qu'il n'y a pas eu de surapprentissage significatif.

5.2 Évaluation sur le test

- Précision globale : 88.5%
- Perte : 0.4242




FIGURE 6 – Exemple de prédiction réalisée par le modèle sur quelques images du jeu de test.




FIGURE 7 – Exemple de prédiction réalisée par le modèle sur quelques images du jeu de test d'une autre data.

5.3 Rapport de classification

Classe	Précision	Rappel	F1-score
COVID	1.00	0.87	0.93
Normal	0.83	0.94	0.88
Virus	0.88	0.84	0.86
Moyenne pondérée	0.89	0.89	0.89

TABLE 2 – Rapport de classification

Le rapport de classification met en évidence les performances du modèle pour chaque classe cible.

Pour la classe **COVID-19**, la précision est parfaite (1.00), indiquant que toutes les prédictions positives COVID sont correctes. Le rappel (0.87) montre cependant que 13 % des cas de COVID ont été mal classés. Le **F1-score** de 0.93 traduit un bon compromis entre ces deux mesures, soulignant une excellente performance globale sur cette classe critique.

Pour la classe **Normal**, un rappel élevé (0.94) indique que la plupart des cas normaux ont été correctement détectés. En revanche, la précision (0.83) légèrement inférieure révèle que le modèle confond parfois d'autres types d'images avec des images normales. Le F1-score associé (0.88) reste toutefois élevé, signalant une bonne fiabilité.

Concernant la classe **Virus** (autre que COVID), le modèle atteint une précision de 0.88 et un rappel de 0.84, avec un F1-score de 0.86. Cela montre une performance solide, bien que légèrement inférieure aux deux autres classes, ce qui peut s'expliquer par la similarité visuelle de certains cas avec les autres catégories.

Enfin, la moyenne pondérée des scores (0.89) reflète une performance homogène sur l'ensemble des classes, ce qui valide la robustesse du modèle sur le jeu de test.

5.4 Confusions possibles

Des confusions ont été observées entre les classes *virus* et *normal*, ainsi que quelques cas de COVID prédits comme *virus* et *normal*.




FIGURE 8 – Matrice de confusion

```

Classe: covid
Vrais Positifs (TP): 26
Faux Positifs (FP): 0
Faux Négatifs (FN): 4
Vrais Négatifs (TN): 92
-----
Classe: normal
Vrais Positifs (TP): 45
Faux Positifs (FP): 9
Faux Négatifs (FN): 3
Vrais Négatifs (TN): 65
-----
Classe: virus
Vrais Positifs (TP): 37
Faux Positifs (FP): 5
Faux Négatifs (FN): 7
Vrais Négatifs (TN): 73
-----

```

La matrice de confusion est un outil utilisé pour évaluer les performances d'un modèle de classification. Elle permet de visualiser la correspondance entre les prédictions du modèle et les véritables étiquettes de classe.

Dans notre cas, la matrice de confusion affiche les résultats de la prédiction sur le jeu de données de test. Elle est composée de trois classes (ou étiquettes) : COVID, Normal, et Virus.

La première classe (COVID) a été prédite correctement 26 fois, mais a été confondue 2 fois avec des images de la classe Normal, et 2 fois avec des images de la classe Virus.

La deuxième classe (Normal) a été prédite correctement 45 fois, mais 3 images ont été mal classées comme Virus.

La troisième classe (Virus) a été correctement identifiée dans 37 cas, mais a été confondue 7 fois avec la classe Normal.

Classe COVID-19 :

- **Vrais positifs (TP)** : 26 images COVID correctement classées comme COVID.
- **Faux positifs (FP)** : 2 images d'autres classes classées à tort comme COVID.
- **Faux négatifs (FN)** : 4 images COVID prédites à tort comme normal ou virus.
- **Vrais négatifs (TN)** : 90 images non-COVID correctement classées comme non-COVID.

Classe Normal :

- **Vrais positifs (TP)** : 45 images normales bien classées.
- **Faux positifs (FP)** : 9 images d'autres classes classées à tort comme normales.
- **Faux négatifs (FN)** : 3 images normales mal classées.
- **Vrais négatifs (TN)** : 65 images non-normales correctement rejetées.

Classe Virus (non-COVID) :

- **Vrais positifs (TP)** : 37 images virales bien prédites.
- **Faux positifs (FP)** : 5 images mal classées comme virus.
- **Faux négatifs (FN)** : 7 images virales classées à tort.
- **Vrais négatifs (TN)** : 73 autres images correctement étiquetées comme non-virus.

Ces résultats montrent que le modèle distingue très bien la classe *COVID-19* et *Normal*, mais présente des confusions plus fréquentes entre les images *virus* et les autres catégories, ce qui reflète la difficulté liée à la similarité visuelle entre certains cas pathologiques.

6. Limites et Perspectives

Limites du modèle

Malgré les résultats satisfaisants obtenus, plusieurs limites ont été identifiées dans notre approche :

- **Taille réduite du jeu de test** : Le modèle a été évalué sur un ensemble relativement restreint de **122 images**. Par après sur **66 images** des données test d'une autre base de donnée. Une telle taille limite la capacité à généraliser les performances

et peut introduire un biais statistique dans l'évaluation (ne reflète pas toute la diversité des cas possibles).

- **Forte variabilité intra-classe** : Certaines classes, en particulier les images de patients atteints de virus autres que la COVID-19, présentent une **variabilité importante** au niveau visuel. Cette hétérogénéité complique la tâche de classification et augmente le risque de confusion entre classes.

Perspectives d'amélioration

Afin d'optimiser les performances futures du modèle, plusieurs pistes d'amélioration peuvent être envisagées :

- **Utilisation de réseaux de neurones convolutifs plus profonds** : L'adoption de modèles préexistants et performants comme **VGG16**, **VGG19** ou **ResNet** permettrait de mieux capturer les caractéristiques complexes des images médicales, tout en bénéficiant de leur capacité à généraliser sur des données variées.
- **Augmentation du volume de données** : Un des leviers essentiels reste l'accès à un **plus grand nombre d'images annotées**. Cela permettrait d'améliorer la robustesse du modèle et de limiter le sur-apprentissage (*overfitting*).
- **Apprentissage par transfert (Transfer Learning)** : L'intégration du *transfer learning*, en réutilisant les poids d'un modèle pré-entraîné sur une large base de données (comme *ImageNet*), offre un moyen efficace de compenser le manque de données tout en bénéficiant d'une représentation riche et déjà optimisée pour l'extraction de caractéristiques visuelles.

7. Conclusion

Le modèle CNN mis en place démontre une capacité intéressante à classer des radiographies thoraciques selon trois catégories, avec une excellente performance pour la détection de la COVID-19. Il pourrait devenir un outil d'aide

au diagnostic dans des contextes cliniques réels, après validation sur des bases plus variées.[4]

Références

- Goodfellow, Bengio & Courville, 2016 [1]
- TensorFlow/Keras (Chollet, 2015), Scikit-learn (Pedregosa et al., 2011) et Matplotlib (Hunter, 2007) [2]
- <https://www.kaggle.com/code/ahmedabdellahismail/detection-of-covid-19-by-chest-x-ray-using-cnn?scriptVersionId=169315153&cellId=1> [3]
- Chowdhury et al., 2020 [4]

Lien code et bases de données.

[Cliquez ici pour voir le code sur GitHub](#)

[Cliquez ici pour voir la base de données pré-traitée](#)

[Cliquez ici pour voir la base de données originale](#)